Khaled Swaidan

AI Engineer – GenAI, RAG & On-Premise LLMs | M.Sc. Informatik

Schwachhausen, 28211 Bremen • khaled.swaidan.k@gmail.com • Verfügbar ab sofort

Profil

AI Engineer und Consultant (M.Sc. Informatik, Thesis 1,0) mit Fokus auf die Entwicklung skalierbarer GenAI-Services, RAG-Pipelines und sicherer On-Premise-LLM-Infrastrukturen. Ich verbinde fundierte Python-Kenntnisse (FastAPI, LangChain) mit praktischer Erfahrung in Docker, Evaluierung von Modellen und der Implementierung von Guardrails (AST-Validierung) für Compliance-Anforderungen.

Berufserfahrung

Softwareentwickler (Cloud & Automation) 02/2025–04/2026

Rocket-Code

- **DevOps & Infrastruktur:** Anbindung von Enterprise-Anwendungen an Azure Functions; Entwicklung von Git Hooks für automatisierte Code-Reviews und CI/CD-nahe Prozesse.
- **Qualitätssicherung:** Implementierung von Testroutinen und Monitoring zur Sicherstellung der Systemstabilität.
- **AI-Driven Development:** Täglicher Einsatz von KI-Tools (ChatGPT, Claude) mit kritischer Prüfung der Ergebnisse.

Junior IT-Berater – Requirements & Evaluation 11/2023–07/2024

IFIB Consult

- **Technische Beratung & Doku:** Analyse von Geschäftsprozessen, Übersetzung in technische Spezifikationen und Erstellung von Dokumentationen für Stakeholder.
- **Troubleshooting & Testing:** Externe Evaluationsstelle für Softwareprojekte; Fehleranalyse und Qualitätssicherung.

Projekte & GenAI-Erfahrung

SIRcraft AI Platform – Masterarbeit 10/2025–10/2026

Universität Bremen | Note 1,0

- **RAG & GenAI-Services:** Aufbau einer End-to-End RAG-Pipeline mit LangChain; semantisches Chunking und Vektordatenbank (ChromaDB mit HNSW-Index) für interne Wissensdatenbanken.
- **On-Premise & Deployment:** Vollständig lokales Hosting von Open-Source-Modellen (Gemma 2, Gemma 4, DeepSeek-R1) via Ollama in einer sicheren, netzwerkgetrennten Umgebung (Zero External API Dependencies); Deployment via Docker Compose.
- **Security & Compliance:** Entwicklung eines Python-basierten AST-Parsers (Recursive Descent) als Guardrail zur Validierung von LLM-Ausgaben gegen formale Grammatiken und zur Absicherung gegen Prompt-Injections.
- **Evaluation & Benchmarking:** Test und Bewertung von vier LLMs anhand eines 30-Fragen-Katalogs hinsichtlich Qualität, Latenz und Sicherheit.

Multi-Tenant Business Application Eigenständiges Projekt

- **Architektur:** Mandantenfähige Plattform mit asynchroner Service-Kommunikation und sicheren Schnittstellen.

Bildung

M.Sc. Informatik 10/2024–10/2026

Universität Bremen | Gesamtnote 1,8; Masterarbeit 1,0

B.Sc. Informatik 10/2019–09/2024

Universität Bremen

Fachliche Kenntnisse

- **GenAI & LLMs:** RAG-Architekturen, LangChain, ChromaDB, Prompt Engineering, Evaluierung, Open-Source-Modelle (Gemma, DeepSeek), AI-Agenten-Tools (Grundlagen), MCP-Konzepte.
- **Programmierung & APIs:** Python, FastAPI, RESTful APIs, Microservices, OOP, SQL.
- **Infrastruktur & DevOps:** Docker, Docker Compose, Azure, CI/CD, Git, Linux, On-Premise-Betrieb; Grundlagen Kubernetes und vLLM/SGLang.
- **Security & Consulting:** Datensouveränität, AST-Validierung (Guardrails), Cybersecurity-Grundlagen für KI, Requirements Engineering, Dokumentation.

Sprachen

Deutsch (C1) Englisch (C1) Arabisch (Muttersprache)